

Hinweise zur Bearbeitung und Abgabe

Die Lösung der Hausaufgabe muss **eigenständig** erstellt werden. Abgaben, die identisch oder auffällig ähnlich zu anderen Abgaben sind, werden als **Plagiat** gewertet! **Plagiate sind Täuschungsversuche und führen zur Bewertung „nicht bestanden“ für die gesamte Modulprüfung.**

- Bitte nutzen Sie MARS zum Simulieren Ihrer Lösung. Stellen Sie sicher, dass Ihre Abgabe in MARS ausgeführt werden kann.
- Sie erhalten für jede Aufgabe eine separate Datei, die aus einem Vorgabe- und Lösungsabschnitt besteht. Ergänzen Sie bitte Ihren Namen und Ihre Matrikelnummer an der vorgegebenen Stelle. Bearbeiten Sie zur Lösung der Aufgabe nur den Lösungsteil unterhalb der Markierung:
 #+ Loesungsabschnitt
 #+ -----
- Ihre Lösung muss auch mit anderen Eingabewerten als den vorgegebenen funktionieren. Um Ihren Code mit anderen Eingaben zu testen, können Sie die Beispieldaten im Lösungsteil verändern.
- Bitte nehmen Sie keine Modifikationen am Vorgabeabschnitt vor und lassen Sie die vorgegebenen Markierungen (Zeilen beginnend mit #+) unverändert.
- Eine korrekte Lösung muss die bekannten **Registerkonventionen** einhalten. Häufig können trotz nicht eingehaltener Registerkonventionen korrekte Ergebnisse geliefert werden. In diesem Fall werden trotzdem Punkte abgezogen.
- Falls Sie in Ihrer Lösung zusätzliche Speicherbereiche für Daten nutzen möchten, verwenden Sie dafür bitte ausschließlich den **Stack** und keine statischen Daten in den Datensektionen (.data). Die Nutzung des Stacks ist gegebenenfalls notwendig, um die Registerkonventionen einzuhalten.
- Die zu implementierenden Funktionen müssen als Eingaben die Werte in den **Argument-Registern** (\$a0–\$a3) nutzen. Daten in den Datensektionen der Assemblerdatei dürfen nicht direkt mit deren Labels referenziert werden.
- Bitte gestalten Sie Ihren Assemblercode nachvollziehbar und verwenden Sie detaillierte Kommentare, um die Funktionsweise Ihres Assemblercodes darzulegen.
- Die Abgabe erfolgt über ISIS. Laden Sie die zwei Abgabedateien separat hoch.

Aufgabe 1: Postleitzahl finden (10 Punkte)

Aufgabe: Implementieren Sie die Funktion `plz`, welche die Zeichenkette `address` nach einer Postleitzahl (PLZ) durchsucht. Fünf aufeinanderfolgende Ziffern (0-9) sind als Postleitzahl zu verstehen. Falls eine Postleitzahl gefunden wurde, soll diese als Zahlenwert zurückgegeben werden. Falls keine Postleitzahl gefunden wurde, soll 0 zurückgegeben werden. Die C-Signatur der zu implementierenden Funktion ist:

```
int plz( char *address);  
$v0          $a0
```

Bei `address` handelt es sich um einen Pointer zum ersten Zeichen einer Zeichenkette. Diese Zeichenkette endet mit einem Nullterminator. Jedes Zeichen ist ein Byte groß und kann anhand des ASCII-Zahlenwerts untersucht werden. Eine ASCII-Tabelle finden Sie zum Beispiel auf der MIPS Green Card.

Test-Eingaben: Testen Sie Ihre Lösung mit unterschiedlichen Eingaben! Bearbeiten Sie dazu die Zeichenkette `test_address`. Folgende Tabelle enthält Beispieleingaben und die erwarteten Rückgabewerte, welche zum Testen verwendet werden können:

| Eingabe-Zeichenkette | Erwartete Ausgabe |
|--------------------------------------|-------------------|
| TU Berlin, 10623 Berlin | 10623 |
| Panoramastraße 1A in 1017 Berlin | 0 |
| Die 4 Bremer (28195) Stadtmusikanten | 28195 |
| 78462 Konstanz Hauptbahnhof | 78462 |

Hinweise:

- Falls mehr als 5 Ziffern aufeinanderfolgen, sollen die ersten fünf aufeinanderfolgenden Ziffern als PLZ gewertet werden (Beispiel "Test 12345678"). Falls die Eingabe mehr als eine PLZ enthält, soll nur die erste PLZ gewertet werden.
- Um eine ASCII-Ziffer in einen Zahlenwert umzurechnen, ziehen Sie den Wert 48 (ASCII '0') ab. Falls das Ergebnis kleiner als 0 oder größer als 9 ist, handelte es sich bei dem Ausgangswert nicht um eine ASCII-Ziffer.
- Um eine Dezimalziffer z an eine Zahl a anzuhängen, rechnen Sie: $a := 10 \cdot a + z$.
- Für die Multiplikation mit 10 können Sie folgenden Trick nutzen: $10 \cdot x = (8 \cdot x) + x + x$. Die Multiplikation mit 8 kann durch eine logische Schiebeoperation umgesetzt werden.

Aufgabe 2: Teilzeichenfolge zählen (10 Punkte)

Aufgabe: Die zu implementierende Funktion `count` soll zählen, wie häufig die Teilzeichenfolge `part` in der Zeichenfolge `text` vorkommt, und die Häufigkeit der Teilzeichenfolge zurückgeben. `part` und `text` sind nullterminierte Zeichenketten. Um die Aufgabe zu lösen, muss die vorgegebene Hilfsfunktion `rollhash` verwendet werden. Die C-Signatur der zu implementierenden Funktion lautet:

```
int count( char *text, char *part);
$V0      $A0      $A1
```

Hilfsfunktion: Eine Hashfunktion liefert für eine Zeichenkette einen Hashwert. Der Hashwert ist eine Art Fingerabdruck der Zeichenkette. Die Hashwerte von identischen Zeichenketten sind ebenfalls identisch¹. Die Besonderheit einer *rollenden Hashfunktion* ist, dass zu der betrachteten Zeichenkette dynamisch Zeichen hinzugefügt und entfernt werden können. Die gehashte Zeichenkette bezeichnen wir als *Hashfenster*.

Die Hilfsfunktion `rollhash` implementiert eine solche rollende Hashfunktion²: Das Zeichen `in` wird hinten zum Hashfenster hinzugefügt (angehängt); das Zeichen `out` vorn aus dem Hashfenster entfernt. Falls kein Zeichen hinzugefügt bzw. entfernt werden soll, kann als `in` bzw. `out` der Wert 0 übergeben werden. Der übergebene Hashwert (Funktionsargument `hash`) wird durch das Hinzufügen und/oder Entfernen von Zeichen verändert, wobei `rollhash` den neuen Hashwert zurückgibt. Die C-Signatur von `rollhash` ist:

```
int rollhash( int hash, char in, char out);
$V0          $A0      $A1      $A2
```

¹Es ist auch möglich, dass zwei *unterschiedliche* Zeichenketten den gleichen Hashwert liefern (Kollision). Dies ignorieren wir in der Aufgabe.

²Hintergrund: `rollhash` verwendet als Hashwerte Permutationen der Länge 8. In hexadezimaler Darstellung enthält dabei ein Hashwert jede Ziffer zwischen 0 und 7 genau einmal. Diese rollende Hashfunktion nutzt Eigenschaften der symmetrischen Gruppe aus (https://de.wikipedia.org/wiki/Symmetrische_Gruppe). Zum Lösen der Aufgabe ist dieser Hintergrund nicht wichtig.

Vorgehen: Es müssen zwei Hashwerte gespeichert werden: ein Hashwert p für $part$ und ein Hashwert t für $text$. Zum Durchlaufen der Zeichenkette $part$ muss eine Position gespeichert werden. Zum Durchlaufen der Zeichenkette $text$ müssen **zwei** Positionen gespeichert werden.

1. *Initialisierungsphase:* Beide Hashwerte müssen zunächst auf 0x76543210 (Hashwert der leeren Zeichenkette) gesetzt werden.
Sei n die Länge von $part$. Alle n Zeichen aus $part$ müssen nun der Reihe nach durch Aufruf von `rollhash` zu p hinzugefügt werden. Außerdem müssen die ersten n Zeichen von $text$ durch Aufruf von `rollhash` zu t hinzugefügt werden.
Nach der Initialisierungsphase wird p nicht mehr verändert.
2. *Suchphase:* In dieser Phase wird nur noch $text$ durchlaufen.
Falls zu Beginn eines Schritts der Suchphase $t = p$ ist, wurde $part$ in $text$ gefunden und die Häufigkeit muss um 1 erhöht werden.
Dann wird durch Aufruf von `rollhash` ein Zeichen zu t hinzugefügt und ein Zeichen entfernt. Das hinzuzufügende Zeichen steht immer n Zeichen hinter dem zu entfernenden Zeichen.
In der Suchphase wird $text$ durchlaufen, bis der Nullterminator erreicht wurde und kein Zeichen mehr zu t hinzugefügt werden kann.

Bei diesem Vorgehen handelt es sich um den Rabin-Karp-Algorithmus³.

Beispiel: Die folgende Tabelle zeigt den Ablauf für $text = "AxyzTESTxyz1xyxyz"$, $part = "xyz"$. **Grün** hinterlegte Zeichen werden in dem jeweiligen Schritt zum Hashfenster hinzugefügt, **rot** hinterlegte Zeichen aus dem Hashfenster entfernt. In der Initialisierungsphase werden in diesem Beispiel $part$ und $text$ zugleich durchlaufen. Dadurch muss n , die Länge von $part$, in der Programmlogik nicht explizit bestimmt werden.

| Hashfenster text | Hashwert text | Hashfenster part | Hashwert part |
|-------------------------------------|-------------------|----------------------------|-------------------|
| <i>Initialisierungsphase:</i> | | | |
| | 0x76543210 | | 0x76543210 |
| A | 0x36124057 | x | 0x42163705 |
| A x | 0x32076514 | x y | 0x07431265 |
| A x y | 0x17623540 | x y z | 0x13207564 |
| <i>Suchphase:</i> | | | |
| A x y z | 0x13207564 | | |
| x y z T | 0x15630742 | | |
| y z T E | 0x56732140 | | |
| z T E S | 0x25014673 | | |
| T E S T | 0x63720154 | | |
| E S T x | 0x30267415 | | |
| S T x y | 0x52670314 | | |
| T x y z | 0x13207564 | | |
| x y z 1 | 0x06714532 | | |
| y z 1 x | 0x17432560 | | |
| z 1 x y | 0x32504167 | | |
| 1 x y x | 0x54630721 | | |
| x y x y | 0x21456037 | | |
| y x y z | 0x13207564 | | |

³Weitere Hintergrundinformationen: <https://de.wikipedia.org/wiki/Rabin-Karp-Algorithmus>

Test-Eingaben: Testen Sie Ihre Lösung mit unterschiedlichen Eingaben! Bearbeiten Sie dazu die Zeichenkette `test_text` und `test_part`. Folgende Tabelle enthält Beispieleingaben und die erwarteten Rückgabewerte, welche zum Testen verwendet werden können:

| Eingabe <code>text</code> | <code>part</code> | Rückgabewert |
|--|-------------------|--------------|
| AxyzTESTxyz1xyxyzxyz1xyz1xyz1xyzHALLOxyz1xyzxyzxyz | xyz | 11 |
| AxyzTESTxyz1xyxyz | xyz | 3 |
| AxyzTESTxyz1xyxyzxyz1xyz1xyz1xyzHALLOxyz1xyzxyzxyz | xyz1xyz | 4 |
| AxyzTESTxyz1xyxyzxyz1xyz1xyz1xyzHALLOxyz1xyzxyzxyz | abc | 0 |
| Zeiger durchlaufen Zeichenketten in kurzer Zeit. | Zei | 3 |

Hinweise:

- Sie können davon ausgehen, dass `text` mindestens gleich lang oder länger als `part` ist. `part` ist außerdem mindestens 1 Zeichen lang.
- Stellen Sie sicher, dass Übereinstimmungen auch ganz am Anfang und ganz am Ende von `text` erkannt und gezählt werden.
- Auch überlappende Übereinstimmungen werden gezählt. Nach diesem Prinzip kommt beispielsweise "xyz1xyz" 3 Mal in "xyz1xyz1xyz1xyz" vor (1. xyz1xyz1xyz1xyz, 2. xyz1xyz1xyz1xyz, 3. xyz1xyz1xyz1xyz).